PROPOSAL TUGAS AKHIR – ET234801

OPTIMALISASI DETEKSI *MILD DIABETIC RETINOPATHY* DENGAN *MULTI-SCALE CROSS-LESION ATTENTION-GATED* GCN DAN *MULTITASK LEARNING*

DIAN ANGGRAENI PUTRI

NRP 5027231016

Dosen Pembimbing 1

Dr. Rizka Wakhidatus Sholikah, S. Kom.

NIP 1993202012054

Dosen Pembimbing 2

Gagatsatya Adiatmaja, S.T., M.Kom.

NIP 1998202611005

Program Studi Teknologi Informasi

Departemen Teknologi Informasi

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

2026

LEMBAR PENGESAHAN

OPTIMALISASI DETEKSI *MILD DIABETIC RETINOPATHY* DENGAN *MULTI-SCALE CROSS-LESION ATTENTION-GATED* GCN DAN *MULTITASK LEARNING*

PROPOSAL TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat
memperoleh gelar Sarjana Komputer pada
Program Studi S-1 Teknologi Informasi
Departemen Teknologi Informasi
Fakultas Teknologi Elektro dan Informatika Cerdas
Institut Teknologi Sepuluh Nopember

Oleh : **Dian Anggraeni Putri**
NRP. 5027231016

Disetujui oleh Tim Penguji Proposal Tugas Akhir :

1. Dr. Rizka Wakhidatus Sholikah, S. Kom. Pembimbing
2. Gagatsatya Adiatmaja, S.T., M.Kom. Ko-pembimbing

SURABAYA
September, 2026

ABSTRAK

OPTIMALISASI DETEKSI *MILD DIABETIC RETINOPATHY* DENGAN *MULTI-SCALE CROSS-LESION ATTENTION-GATED* GCN DAN *MULTITASK LEARNING*

Nama Mahasiswa / NRP	**:**	**Dian Anggraeni Putri / 5027231016**
Departemen	**:**	**Teknologi Informasi**
Dosen Pembimbing	**:**	**Dr. Rizka Wakhidatus Sholikah, S. Kom.**
		Gagatsatya Adiatmaja, S.T., M.Kom.

Abstrak

Diabetic Retinopathy (DR) merupakan penyebab utama kebutaan pada usia produktif, dengan prevalensi yang diproyeksikan mencapai 160 juta jiwa pada tahun 2045. Deteksi dini tahap *Mild Non-Proliferative Diabetic Retinopathy* (Mild NPDR) menjadi tantangan kritis karena ukuran mikroaneurisma yang sangat halus serta ketidakseimbangan distribusi kelas pada dataset. Model *deep learning* konvensional sering kali mengalami keterbatasan dalam menangkap dependensi spasial antar-lesi dengan variasi ukuran yang berbeda (seperti mikroaneurisma, eksudat, dan perdarahan), sehingga sensitivitas pada kelas *Mild* cenderung rendah. Penelitian ini mengusulkan arsitektur *hybrid* berbasis VGG19 dan *Graph Convolutional Network* (GCN) yang diperkuat dengan modul *Multi-Scale Cross-Lesion Attention* (MS-CLA). Modul MS-CLA diintegrasikan untuk mengagregasi fitur dari tiga tingkatan kedalaman VGG19 melalui mekanisme *cross-attention*, sehingga *node* graf yang terbentuk memiliki representasi fitur yang terboboti berdasarkan relevansi lesi lintas-skala. Pendekatan ini mentransformasi GCN konvensional menjadi *Attention-Gated GCN* yang lebih peka terhadap hubungan semantik antar-lesi. Selain itu, *pipeline* praproses ditingkatkan dengan normalisasi *LAB Color Space* untuk menstabilkan distribusi luminansi antar-dataset yang berasal dari berbagai sumber. Pengujian dilakukan pada dataset APTOS 2019 melalui *5-Fold Cross-Validation* serta evaluasi generalisasi pada dataset Messidor-2. Hasil penelitian ini diharapkan mampu meningkatkan sensitivitas deteksi *Mild NPDR* secara signifikan melalui representasi fitur yang lebih terarah dan adaptif terhadap variasi karakteristik lesi.

Kata kunci: ***Diabetic Retinopathy, Mild NPDR, VGG19, Multi-Scale Cross-Lesion Attention, GCN, Multitask Learning.***

ABSTRACT

OPTIMIZATION OF MILD DIABETIC RETINOPATHY DETECTION USING MULTI-SCALE CROSS-LESION ATTENTION-GATED GCN AND MULTITASK LEARNING

Student Name / NRP	**:**	**Dian Anggraeni Putri / 5027231016**
Department	**:**	**Information Technology**
Advisor	**:**	**Dr. Rizka Wakhidatus Sholikah, S. Kom.**
		Gagatsatya Adiatmaja, S.T., M.Kom.

Abstract

Diabetic Retinopathy (DR) is a leading cause of blindness among individuals of working age, with its prevalence projected to reach 160 million cases by 2045. Early detection of Mild Non-Proliferative Diabetic Retinopathy (Mild NPDR) remains a critical challenge due to the extremely subtle size of microaneurysms and the imbalanced class distribution in the dataset. Conventional deep learning models often face limitations in capturing spatial dependencies among lesions with varying sizes, such as microaneurysms, exudates, and hemorrhages, resulting in relatively low sensitivity for the Mild class. This study proposes a hybrid architecture based on VGG19 and a Graph Convolutional Network (GCN), enhanced with a Multi-Scale Cross-Lesion Attention (MS-CLA) module. The MS-CLA module is integrated to aggregate features from three different depth levels of VGG19 through a cross-attention mechanism, enabling the resulting graph nodes to possess feature representations weighted according to the relevance of lesions across different scales. This approach transforms the conventional GCN into an Attention-Gated GCN that is more sensitive to semantic relationships among lesions. In addition, the preprocessing pipeline is enhanced with LAB Color Space normalization to stabilize luminance distributions across datasets obtained from different sources. The model is evaluated on the APTOS 2019 dataset using 5-Fold Cross-Validation, followed by a generalization evaluation on the Messidor-2 dataset. The proposed approach is expected to significantly improve the sensitivity of Mild NPDR detection through more targeted feature representations that are adaptive to variations in lesion characteristics.

Keywords: ***Diabetic Retinopathy, Mild NPDR, VGG19, Multi-Scale Cross-Lesion Attention, GCN, Multitask Learning.***

DAFTAR ISI

LEMBAR PENGESAHAN i
ABSTRAK ii
ABSTRACT iii
DAFTAR ISI iv
BAB 1 PENDAHULUAN 1
1.1 Latar Belakang 1
1.2 Rumusan Masalah 2
1.3 Batasan Masalah 2
1.4 Tujuan 2
1.5 Manfaat 3
BAB 2 TINJAUAN PUSTAKA 4
2.1 Hasil Penelitian Terdahulu 4
2.2 Dasar Teori 5
BAB 3 METODOLOGI 11
3.1 Metode yang digunakan 11
3.2 Bahan dan peralatan yang digunakan 16
3.3 Urutan pelaksanaan penelitian 17
3.4 Jadwal Kegiatan 17
DAFTAR PUSTAKA 18

BAB 1 PENDAHULUAN

1.1 Latar Belakang

Diabetes melitus menjadi salah satu beban kesehatan terberat abad ke-21. *International Diabetes Federation* mencatat 537 juta penderita diabetes global pada 2021, diproyeksikan naik menjadi 783 juta pada 2045 (IDF, 2021). Indonesia menyumbang 19,5 juta penderita pada 2021, diperkirakan tumbuh menjadi 28,6 juta pada 2045, menjadikannya negara dengan jumlah penderita diabetes terbesar kelima di dunia (IDF, 2021).

Diabetic Retinopathy (DR) adalah salah satu komplikasi mikrovaskular diabetes yang paling mengkhawatirkan karena menjadi penyebab utama gangguan penglihatan dan kebutaan pada usia produktif secara global (Tsiknakis et al., 2021). Meta-analisis global menunjukkan sekitar 22,27% penderita diabetes mengalami DR, dengan jumlah penderita diproyeksikan meningkat dari 103,12 juta pada 2020 menjadi 160,50 juta pada 2045 (Teo et al., 2021).

Deteksi dini sangat krusial karena *Mild Non-Proliferative Diabetic Retinopathy* (Mild NPDR) merupakan tahap awal DR yang terutama ditandai oleh keberadaan mikroaneurisma (Dubey & Dixit, 2023). Lesi pada tahap ini berukuran kecil dan memiliki karakteristik visual yang relatif halus sehingga menjadi salah satu tahap yang paling sulit dibedakan pada proses *grading* DR berbasis citra fundus (Tsiknakis et al., 2021). Padahal, identifikasi pada tahap awal diperlukan untuk memungkinkan pemantauan dan penanganan sebelum penyakit berkembang menuju tahap yang lebih berat dan berpotensi menyebabkan gangguan penglihatan permanen (Kropp et al., 2023).

Convolutional Neural Network (CNN) banyak digunakan untuk klasifikasi DR karena mampu mengekstraksi fitur visual secara hierarkis, namun representasi berbasis konvolusi masih memiliki keterbatasan dalam memodelkan hubungan eksplisit antarwilayah yang berjauhan pada citra (Feng et al., 2023). Permasalahan ini semakin kompleks pada Mild DR karena lesi yang menjadi indikator utama berukuran kecil. Selain itu, ketimpangan distribusi kelas turut menjadi tantangan, dengan kelas Mild hanya 10,1% sampel APTOS 2019, sementara No DR mendominasi 49,3% (Dai et al., 2021), sehingga model berpotensi lebih bias terhadap kelas mayoritas (Mungloo-Dilmohamud et al., 2022). Pendekatan *hybrid* CNN dengan *Graph Convolutional Network* (GCN) dikembangkan untuk memodelkan relasi spasial antar-*patch* melalui *message passing* (Feng et al., 2023). Ditambah *Multitask Learning* (MTL) berupa klasifikasi biner Mild vs Non-Mild, arsitektur *hybrid* CNN-GCN-MTL berbasis EfficientNet-B0 terbukti meningkatkan sensitivitas Mild DR, dengan *recall* Mild 0,8649 (*in-domain* APTOS 2019) dan peningkatan relatif 64,4% (*cross-domain* Messidor-2) (Harjanto, 2025).

Meski demikian, pendekatan ini menyisakan dua keterbatasan. Pertama, *backbone* EfficientNet-B0 menggunakan *compound scaling* untuk menyeimbangkan akurasi dan efisiensi komputasi (Tan & Le, 2019), sehingga masih terbuka peluang untuk mengeksplorasi *backbone* dengan representasi fitur *fine-grained*. Kedua, GCN standar belum memiliki mekanisme *attention* untuk membedakan relevansi hubungan antarnode berdasarkan karakteristik fitur (Veličković et al., 2018). Akibatnya, *patch* yang mengandung mikroaneurisma belum dapat diprioritaskan secara adaptif, sementara hubungan antarlesi dengan karakteristik berbeda belum dimodelkan secara optimal (Xia et al., 2024).

Liu dan Chi (2023) mengidentifikasi persoalan serupa pada *grading* DR dan mengusulkan *Cross-Lesion Attention Network* (CLANet), yang terdiri atas modul *Adaptive Lesion-Aware* (ALA) berbasis *Adaptive Channel-Spatial Convolution* (ACSConv) serta *Cross-Scale Context Attention* (CSCA). Pendekatan tersebut memanfaatkan informasi multiskala untuk menangkap karakteristik lesi yang memiliki perbedaan bentuk, ukuran, dan lokasi sekaligus mengeksplorasi dependensi antarlesi. CLANet menunjukkan performa yang kompetitif pada dataset IDRiD, Messidor, dan DDR, sehingga menunjukkan bahwa pemodelan informasi lintas-lesi dan lintas-skala relevan untuk meningkatkan representasi fitur pada citra fundus (Liu & Chi, 2023).

Prinsip tersebut berpotensi melengkapi GCN dengan memberikan representasi *node* yang lebih selektif sebelum proses *message passing*.

Pemilihan *backbone* CNN juga dapat dioptimalkan. VGG19 memiliki struktur konvolusi 3×3 yang dalam dan seragam sehingga mampu membentuk representasi fitur secara hierarkis dan mempertahankan informasi visual pada berbagai tingkat abstraksi (Simonyan & Zisserman, 2015). Penggunaan VGG19 juga telah dieksplorasi pada analisis citra fundus untuk klasifikasi DR (Najjar et al., 2025). Eksplorasi awal yang membandingkan VGG19, VGG16, dan Swin-Tiny dengan *pipeline* identik menunjukkan VGG19 unggul, dengan *recall* Mild tertinggi sebesar 90,00% ± 4,06%.

Berdasarkan temuan tersebut, penelitian ini mengusulkan arsitektur *hybrid* VGG19 *Multi-Scale Cross-Lesion Attention* (MS-CLA)-GCN dengan *Multitask Learning*, dengan menyisipkan modul MS-CLA di antara *backbone* VGG19 dan GCN. Modul ini mengambil fitur dari tiga skala kedalaman VGG19 (blok ketiga, keempat, kelima), lalu melakukan *cross-attention* antarskala untuk membentuk representasi *node* yang diboboti berdasarkan relevansi lintas-skala sebelum diproses oleh GCN. Dengan demikian, informasi yang diteruskan pada proses *message passing* diharapkan lebih berfokus pada *patch* yang memiliki karakteristik relevan terhadap lesi DR. Sebagai pelengkap *pipeline* praproses *Green-CLAHE* dan *auto-cropping*, penelitian ini menambahkan transformasi *LAB Color Space* untuk memisahkan komponen luminansi dari informasi warna sehingga variasi pencahayaan pada citra fundus dapat dinormalisasi secara lebih konsisten (Priyadharsini & Kannan, 2023).

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah penelitian ini adalah sebagai berikut:

1. Bagaimana peran modul *Multi-Scale Cross-Lesion Attention* (MS-CLA) dalam memperkaya representasi fitur VGG19 untuk meningkatkan sensitivitas deteksi lesi mikroskopis *Mild DR*?
2. Bagaimana penerapan *Multitask Learning* dapat meningkatkan kemampuan model dalam mendeteksi *Mild* DR?
3. Bagaimana performa dan generalisasi arsitektur VGG19-GCN-MTL pada berbagai *dataset* citra *fundus* retina?

1.3 Batasan Masalah

Penelitian ini memiliki batasan-batasan sebagai berikut:

1. Penelitian ini membatasi klasifikasi citra fundus retina pada lima tingkatan keparahan DR yaitu *No DR, Mild, Moderate, Severe,* dan *Proliferative*.
2. Dataset yang digunakan terdiri dari APTOS 2019 sebagai data utama, serta DDR, IDRiD, dan Messidor-2 sebagai data pengujian generalisasi (*cross-domain*).
3. Arsitektur model menggunakan VGG19 sebagai *backbone*, dengan penyisipan modul *Multi-Scale Cross-Lesion Attention* (MS-CLA) untuk memboboti fitur sebelum pemodelan spasial menggunakan GCN dan klasifikasi melalui *Multitask Learning*.
4. Operasi modul MS-CLA terbatas pada agregasi fitur dari tiga blok konvolusi terakhir VGG19 (blok 3, 4, dan 5).
5. Teknik *preprocessing* utama mencakup *Green-CLAHE* dan *auto-cropping*, yang dikombinasikan dengan normalisasi *LAB Color Space* untuk standarisasi input.
6. Metrik evaluasi model difokuskan pada *recall Mild, accuracy, Area Under the Curve* (AUC), dan *Quadratic Weighted Kappa* (QWK).

1.4 Tujuan

Tujuan penelitian ini adalah:

1. Mengembangkan arsitektur *VGG19-MS-CLA-GCN-MTL* dengan menerapkan modul *Multi-Scale Cross-Lesion Attention* (MS-CLA) untuk memperkaya representasi fitur dan meningkatkan sensitivitas deteksi lesi mikroskopis pada *Mild DR*.

2. Mengintegrasikan MS-CLA ke dalam struktur GCN untuk meningkatkan kemampuan model dalam menangkap dependensi spasial antar-lesi serta mengatasi keterbatasan agregasi isotropik.
3. Mengevaluasi efektivitas arsitektur *VGG19-MS-CLA-GCN-MTL* berdasarkan akurasi, sensitivitas, dan kemampuan generalisasi dalam deteksi *Mild DR*.

1.5 Manfaat

Penelitian ini diharapkan memberikan manfaat sebagai berikut:

1. Bagi dunia kesehatan, penelitian ini menyediakan sistem deteksi dini *Mild DR* yang lebih sensitif untuk mencegah progresi penyakit menuju tahap kebutaan permanen.
2. Bagi pengembangan ilmu pengetahuan, penelitian ini memberikan kontribusi teoretis mengenai efektivitas mekanisme *multi-scale attention* dalam memperkuat representasi fitur pada arsitektur *hybrid* CNN-GCN.
3. Bagi penelitian selanjutnya, penelitian ini menjadi acuan dalam pengembangan arsitektur *attention-gated graph neural network* yang lebih adaptif terhadap kompleksitas lesi mikroskopis pada citra medis.
4. Bagi praktisi klinis, penelitian ini mendukung pengambilan keputusan medis yang lebih akurat melalui visualisasi *Grad-CAM* dan pemetaan atensi yang memberikan transparansi atas diagnosis sistem AI.

BAB 2 TINJAUAN PUSTAKA

2.1 Hasil Penelitian Terdahulu

Penelitian ini didasari pada beberapa hasil penelitian terdahulu sebagai pedoman dan referensi dalam proses penelitian ini. Informasi yang disampaikan dalam Tabel 2.1 berisi informasi mengenai penelitian sebelumnya, hasil penelitian, dan hubungan terhadap penelitian ini.

Tabel 2.1 Studi Sebelumnya

No	Tahun & Penulis	Pembahasan
1	*Grading of Diabetic Retinopathy Images Based on Graph Neural Network*, Feng, M., Wang, J., Wen, K., & Sun, J. (2023)	Penelitian ini mengusulkan model dua cabang yang menggabungkan CNN (*DenseNet121*) dan *Graph Neural Network* (GNN). CNN digunakan untuk ekstraksi fitur awal dari citra *fundus*, sedangkan GNN dua lapis dibangun dari hasil *feature map* CNN dengan *adjacency matrix* berbasis *k-nearest neighbors* (KNN), tanpa mekanisme *attention* apa pun sebelum *node* dibentuk. Model diuji pada APTOS 2019 dan Messidor-2 dan menunjukkan peningkatan akurasi sebesar +1,1% dan *F1-score* sebesar +1,3% dibanding *baseline* CNN. Penelitian ini menjadi dasar motivasi awal penggunaan komponen GCN pada tugas akhir ini, namun agregasi fitur yang digunakan bersifat isotropik (bobot antar-*node* seragam), sehingga menjadi salah satu titik yang diperbaiki melalui penyisipan modul MS-CLA sebelum GCN pada penelitian ini.
2	*Peningkatan Sensitivitas Deteksi Mild Diabetic Retinopathy Menggunakan Arsitektur Hybrid CNN-GNN dengan Multitask Learning*, Harjanto, S. A. (2025)	Penelitian ini mengembangkan arsitektur *hybrid* CNN-GCN dengan *Multitask Learning* (MTL) menggunakan *EfficientNet-B0* sebagai *backbone*, lima varian representasi graf (*Grid-4*, *Grid-8*, KNN k=6, k=8, k=12), dan *feature map* tunggal dari lapisan akhir *backbone* yang langsung dikonversi menjadi *node* graf. Pada evaluasi *in-domain* APTOS 2019, model terbaik (KNN k=8) mencapai *recall Mild* sebesar 0,8649; pada evaluasi *cross-domain* Messidor-2, arsitektur ini meningkatkan *recall Mild* sebesar 64,4% dibanding CNN *baseline*. Penelitian ini menjadi *baseline* langsung (*direct baseline*) yang dikembangkan dalam tugas akhir ini. Dua keterbatasan utamanya, yaitu (1) *backbone EfficientNet-B0* yang berpotensi kurang optimal mempertahankan detail *fine-grained*, dan (2) GCN yang memperlakukan seluruh *node* tetangga dengan bobot agregasi seragam (isotropik) dari satu level fitur saja, masing-masing menjadi dasar dari dua kontribusi penelitian ini: penggantian *backbone* menjadi VGG19 dan penyisipan modul *Multi-Scale Cross-Lesion Attention* (MS-CLA) sebelum GCN.
3	*A Graph Convolutional Network with Dynamic Weight Fusion of Multi-Scale Local Features for Diabetic Retinopathy Grading*, Wang, Y., Wang, L., Guo, Z.,	Penelitian ini mengembangkan model MDGNet yang menggabungkan modul *Multi-scale Dynamic Fusion* (MSDF) dan GCN. MSDF mengekstrak fitur lesi pada berbagai skala sebelum GCN memproses interaksi spasial antarlesi, dan model ini mencatat performa terbaik dibandingkan metode *state-of-the-art* pada klasifikasi 5 kelas DR di APTOS 2019 dan DDR. MDGNet menjadi bukti pendukung tambahan bahwa fusi multiskala sebelum tahap graf dapat meningkatkan performa GCN, memperkuat rasionalisasi perancangan modul MS-CLA pada penelitian ini; namun MDGNet melakukan fusi statis (*dynamic weight fusion*) tanpa mekanisme

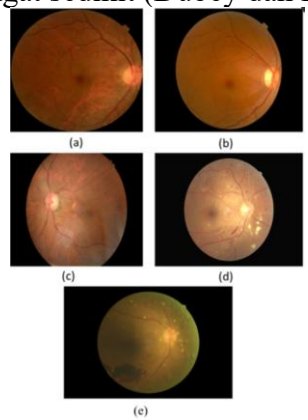
No	Tahun & Penulis	Pembahasan
	Song, S., & Li, Y. (2024)	*cross-attention query-key* eksplisit antarlesi sebagaimana yang diadaptasi dari CLANet pada penelitian ini.
4	*A Cross-Lesion Attention Network for Accurate Diabetic Retinopathy Grading With Fundus Images*, Liu, X., & Chi, W. (2023)	Penelitian ini mengusulkan *Cross-Lesion Attention Network* (CLANet) yang terdiri atas modul *Adaptive Lesion-Aware* (ALA) berbasis *Adaptive Channel-Spatial Convolution* (ACSConv) untuk menyesuaikan *receptive field* terhadap variasi bentuk lesi, serta modul *Cross-Scale Context Attention* (CSCA) yang mengeksplorasi dependensi multiskala antarlesi secara *coarse-to-fine* melalui *Multi-Scale Context Feature Fusion*. CLANet diuji pada IDRiD, Messidor, dan DDR, dan mengungguli pendekatan *state-of-the-art* untuk *grading* DR secara umum, namun tidak memiliki komponen *graph-based reasoning* maupun *multitask supervision*. Penelitian ini menjadi rujukan utama (*primary reference*) dalam merancang modul *Multi-Scale Cross-Lesion Attention* (MS-CLA): prinsip *cross-scale context attention* diadopsi dan diadaptasi menjadi mekanisme *cross-attention* tiga skala (blok konvolusi ketiga, keempat, kelima VGG19) yang disisipkan di antara *backbone* dan GCN, alih-alih menggantikan seluruh *backbone* dengan ACSConv seperti pada CLANet asli, sehingga tetap kompatibel dengan komponen GCN dan MTL yang dipertahankan dari Harjanto (2025).
5	*Retinal Fundus Image Classification for Diabetic Retinopathy Using Transfer Learning Technique*, Mohsen et al. (2023)	Penelitian ini menggunakan dataset APTOS 2019 untuk klasifikasi DR dengan membandingkan empat *backbone pretrained*, yaitu VGG16, VGG19, InceptionV3, dan DenseNet169. InceptionV3 memperoleh akurasi tertinggi sebesar 96,88%, sedangkan VGG19 menunjukkan performa kompetitif. Penelitian ini menjadi salah satu dasar empiris pemilihan VGG19 sebagai *backbone* pada penelitian ini, namun belum melibatkan komponen graf, *attention* multiskala, maupun fokus pada sensitivitas kelas *Mild DR* secara khusus.
6	*VR-FuseNet: A Fusion of Heterogeneous Fundus Data and Explainable Deep Network for Diabetic Retinopathy Classification*, Refat et al. (2026)	Penelitian ini mengusulkan VR-FuseNet yang menggabungkan VGG19 dan ResNet50V2, di mana VGG19 digunakan untuk menangkap *fine-grained spatial features* sedangkan ResNet50V2 mengekstraksi fitur hierarkis yang lebih dalam. Pada APTOS 2019, VGG19 sebagai model tunggal memperoleh akurasi 96,00% dan *recall* 95,164%, memperkuat dasar empiris pemilihan VGG19 sebagai *backbone* yang unggul dalam fitur *fine-grained* pada penelitian ini, meski tidak dievaluasi untuk sensitivitas kelas *Mild DR* maupun diintegrasikan dengan *graph neural network*.

2.2 Dasar Teori

2.2.1 Diabetic Retinopathy (DR)

Diabetic Retinopathy (DR) merupakan komplikasi diabetes mellitus yang menyerang pembuluh darah kecil pada retina dan menjadi penyebab utama kebutaan di kalangan usia produktif. DR secara klinis didefinisikan sebagai penyakit mikrovaskular retina yang merusak kapiler retinal sehingga menimbulkan gangguan penglihatan (Kropp et al., 2023). Tingkat keparahan DR diklasifikasikan menurut skala International Clinical Diabetic Retinopathy (ICDR) menjadi lima kelas, yaitu No DR (tanpa retinopati), Mild NPDR (Non-Proliferatif Ringan), Moderate NPDR, Severe NPDR, dan Proliferative DR (PDR). Mild NPDR (kelas 1)

hanya ditandai oleh adanya setidaknya satu mikroaneurisma tanpa lesi lainnya, yang menjadikannya tahap paling sulit untuk dideteksi secara otomatis karena ukuran lesi yang sangat halus dan jumlahnya yang sangat sedikit (Dubey dan Dixit, 2023).

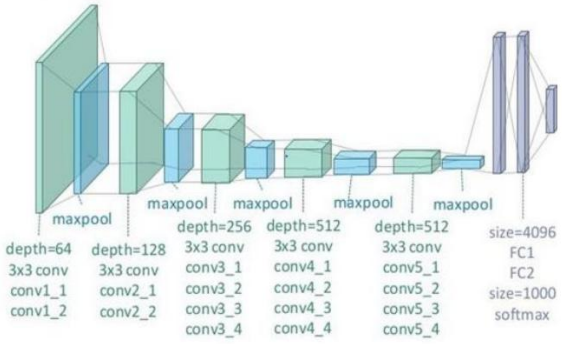


Gambar 2.1 Contoh citra fundus retina pada lima tingkat keparahan Diabetic Retinopathy: (a) *No DR*, (b) *Mild*, (c) *Moderate*, (d) *Severe*, (e) *Proliferative DR* (Alyoubi et al., 2021)

Sensitivitas model deep learning konvensional untuk Mild DR hanya mencapai sekitar 7%, jauh lebih rendah dibanding kelas lainnya (Tsiknakis et al., 2021). Kondisi ini diperparah oleh distribusi data yang tidak seimbang, yaitu pada dataset APTOS 2019 kelas Mild hanya mencakup 10,1% sampel sementara kelas No DR mendominasi sebesar 49,3% (Dai et al., 2021). Selain itu, DR melibatkan beberapa jenis lesi yang berbeda secara morfologis, meliputi mikroaneurisma (MA), perdarahan (HE), eksudat lunak (SE), dan eksudat keras (EX), yang bervariasi dalam bentuk, ukuran, dan lokasi spasial, serta memiliki keterkaitan (dependensi) yang kuat satu sama lain dalam menentukan tingkat keparahan akhir (Liu dan Chi, 2023). Dalam konteks klinis, kasus Mild yang terlewatkan dapat berlanjut menjadi Moderate atau bahkan Proliferative DR yang berpotensi menimbulkan kebutaan permanen apabila tidak mendapat penanganan dini (Kropp et al., 2023).

2.2.2 Deep Learning untuk Klasifikasi Citra Medis

Convolutional Neural Network (CNN) adalah kelas jaringan saraf tiruan yang paling umum digunakan untuk analisis citra medis. CNN secara otomatis mempelajari fitur hierarkis dari data gambar melalui serangkaian lapisan konvolusi, *pooling*, dan *fully connected*, dan merupakan tipe *deep learning* khusus yang memproses data bertopologi *grid* seperti data citra, berbeda dengan jaringan saraf standar yang hanya terdiri atas lapisan *fully connected* (Kim et al., 2022).



Gambar 2.2 Ilustrasi arsitektur VGG19 dengan tumpukan lapisan konvolusi 3×3 yang seragam dan mendalam (Ahmed et al., 2024)

Dalam penelitian ini, VGG19 digunakan sebagai *backbone* CNN. Arsitektur VGG19 tersusun atas lapisan konvolusi 3×3 yang seragam dan mendalam, di mana VGG19 memiliki lapisan konvolusi tambahan dibandingkan VGG16 untuk mendeteksi fitur yang lebih kompleks (Pavithra et al., 2024). Struktur ini menghasilkan lima blok konvolusi (*conv1–conv5*) dengan resolusi spasial yang menurun secara bertahap dan kedalaman *channel* yang meningkat,

sehingga setiap blok merepresentasikan tingkat abstraksi visual yang berbeda. Karakteristik ini menjadikan VGG19 kandidat yang sesuai untuk diambil fitur multiskalanya, karena blok-blok akhirnya (*conv3, conv4, conv5*) secara alami menyediakan representasi pada tiga tingkat resolusi dan semantik yang berbeda tanpa memerlukan modifikasi arsitektural tambahan, berbeda dengan EfficientNet-B0 yang menggunakan *compound scaling* sehingga hierarki fitur antarblok kurang seragam (Tan dan Le, 2019). VGG19 dipilih karena menyediakan kualitas representasi fitur *fine-grained* yang optimal sebagai dasar bagi modul *attention* multiskala dan komponen GCN pada tahap selanjutnya.

2.2.3 Preprocessing Citra Fundus

Citra fundus retina sering memiliki pencahayaan tidak merata dan kontras rendah sehingga lesi halus, seperti mikroaneurisma dan eksudat, sulit diamati (Sule & Viriri, 2022). Untuk mengatasinya, digunakan metode *Contrast Limited Adaptive Histogram Equalization* (CLAHE) yang meningkatkan kontras lokal tanpa memperkuat *noise* secara berlebihan (Madhavi & Kumari, 2024). Pada proses ini, saluran hijau (*green channel*) dipilih karena memberikan kontras terbaik untuk struktur vaskular dan lesi retina (Vanaja & Prakasam, 2025), sedangkan *auto-cropping* diterapkan untuk menghapus area non-retina guna mengurangi kompleksitas komputasi serta menghilangkan artefak latar belakang (Aftab & Akhtar, 2025).

Sebagai penyempurnaan, penelitian ini menerapkan normalisasi *LAB Color Space* sebagai tahap akhir setelah *Green-CLAHE*. *LAB Color Space* memisahkan komponen luminansi (L) dari komponen krominansi (a, b), sehingga variasi pencahayaan antar-kamera dapat dinormalisasi secara independen pada kanal L tanpa mendistorsi informasi klinis pada kanal a dan b (Madhavi & Kumari, 2024). Teknik ini diterapkan untuk menstabilkan distribusi intensitas citra dari berbagai sumber dataset (*APTOS, DDR, IDRiD, dan Messidor-2*) yang memiliki karakteristik kamera yang beragam, sehingga pipeline praproses ini mampu menghasilkan data input yang lebih konsisten bagi arsitektur model yang diusulkan.

2.2.4 Augmentasi Data

Augmentasi data merupakan teknik untuk meningkatkan keragaman data latih melalui modifikasi citra sehingga model dapat melakukan generalisasi lebih baik dan mengurangi *overfitting* (Wang et al., 2025). Teknik yang umum digunakan meliputi rotasi, *horizontal flip*, *zoom*, translasi, serta penyesuaian kecerahan dan kontras. Berbagai transformasi tersebut dapat diterapkan secara efisien menggunakan pustaka *Albumentations* (Buslaev et al., 2020). Pada kasus distribusi data DR yang tidak seimbang, augmentasi pada kelas minoritas menjadi strategi penting untuk mengurangi bias terhadap kelas mayoritas. Mungloo-Dilmohamud et al. (2022) menunjukkan bahwa pendekatan ini dapat meningkatkan kemampuan generalisasi model *transfer learning*. Dalam penelitian ini, diterapkan augmentasi ringan berupa *horizontal flip*, rotasi acak, penyesuaian kecerahan dan kontras, serta *shift-scale-rotate* dengan toleransi kecil untuk menambah keragaman data tanpa mengubah struktur anatomis utama retina.

2.2.5 Fungsi Loss

Fungsi *Cross-Entropy Loss* banyak digunakan pada tugas klasifikasi karena mengukur perbedaan antara distribusi probabilitas prediksi model dan label sebenarnya. Pada data yang tidak seimbang, fungsi ini cenderung bias terhadap kelas mayoritas. Oleh karena itu, digunakan *Weighted Cross-Entropy* yang memberikan bobot lebih besar pada kelas minoritas sehingga kontribusinya terhadap *loss* meningkat (Song et al., 2024). Dalam penelitian ini, pendekatan *multitask learning* menggabungkan dua keluaran, yaitu klasifikasi lima tingkat keparahan DR dan klasifikasi biner *Mild* vs *Non-Mild*. Masing-masing menggunakan fungsi *loss* berbeda, yaitu CrossEntropyLoss untuk klasifikasi multikelas dan BCEWithLogitsLoss berbobot untuk klasifikasi biner. Kedua *loss* kemudian digabungkan, dengan bobot lebih besar pada tugas biner untuk memperkuat sinyal *gradient* terhadap kelas *Mild*.

2.2.6 Metrik Evaluasi

2.2.6.1 *Recall Mild*

Recall kelas *Mild* digunakan sebagai metrik evaluasi utama karena mencerminkan kemampuan model dalam mengenali kasus *Mild* NPDR dengan benar. Metrik ini dihitung menggunakan rumus:

$$Recall = \frac{TP}{TP + FN}$$

TP (*True Positive*) adalah jumlah sampel *Mild* yang diprediksi benar, sedangkan FN (*False Negative*) adalah sampel *Mild* yang salah diklasifikasikan sebagai kelas lain. Dalam konteks klinis, *false negative* pada kelas ini lebih berbahaya dibandingkan *false positive* karena kasus *Mild* yang terlewat dapat berlanjut menjadi *Moderate* atau *Severe* tanpa mendapat penanganan dini.

2.2.6.2 *Accuracy*

Accuracy adalah metrik yang menunjukkan seberapa besar proporsi sampel yang terklasifikasi dengan benar dari seluruh sampel uji, didefinisikan sebagai:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Meskipun akurasi memiliki keterbatasan pada dataset yang tidak seimbang, metrik ini tetap digunakan sebagai tolok ukur sekunder untuk memastikan bahwa peningkatan sensitivitas terhadap *Mild DR* tidak dicapai dengan mengorbankan performa global secara berlebihan.

2.2.6.3 *Area Under Curve* (AUC)

AUC mengukur area di bawah kurva ROC (*Receiver Operating Characteristic*), yang menggambarkan hubungan antara *True Positive Rate* dan *False Positive Rate* pada berbagai ambang keputusan. AUC lebih tahan terhadap ketidakseimbangan kelas dan dapat menilai kualitas pemisahan (*separability*) antarkelas. Dalam klasifikasi DR, AUC penting untuk menilai seberapa baik model membedakan tingkat keparahan terutama pada kategori dengan distribusi data tidak seimbang.

2.2.6.4 *Quadratic Weighted Kappa* (QWK)

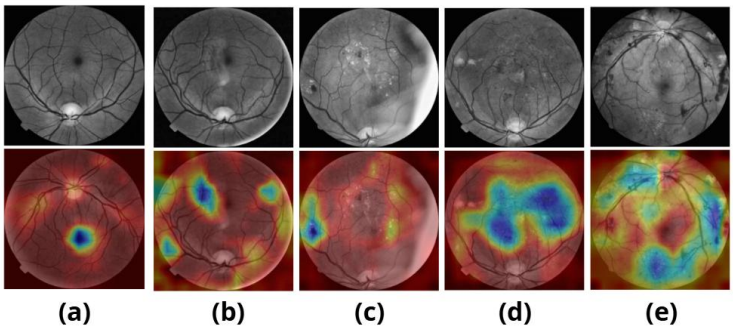
QWK digunakan untuk mengukur kesesuaian antara prediksi model dan label asli dengan memberikan penalti berbeda berdasarkan tingkat kesalahan. DR merupakan masalah klasifikasi ordinal (kelas 0-4), sehingga salah prediksi *Mild* ke *Moderate* tidak sepenting salah prediksi *Mild* ke *Proliferative*. QWK dirancang untuk menilai performa pada situasi klasifikasi berurutan seperti ini secara lebih adil dibanding *accuracy* biasa (Terven et al., 2025).

2.2.6.5 *Confusion Matrix*

Confusion matrix adalah tabel yang menyajikan perbandingan antara prediksi model dan label sebenarnya untuk seluruh kelas. Tabel ini memiliki empat entri utama pada klasifikasi biner yaitu *True Positive* (TP), *False Negative* (FN), *False Positive* (FP), dan *True Negative* (TN), serta dapat diperluas ke bentuk *multiclass* untuk menampilkan distribusi kesalahan antarkelas DR. Matriks ini memudahkan visualisasi kinerja klasifikasi dan menjadi dasar perhitungan metrik lainnya seperti *recall, precision,* dan *F1-score* (Hicks et al., 2022).

2.2.7 *Explainable AI* (Grad-CAM)

Explainable Artificial Intelligence (XAI) berfokus pada pengembangan teknik yang mampu meningkatkan transparansi model pembelajaran mesin kompleks, khususnya dalam domain analisis citra medis (Chen et al., 2022). Salah satu metode XAI yang paling banyak digunakan untuk interpretasi visual adalah *Gradient-weighted Class Activation Mapping* (*Grad-CAM*), yang bekerja dengan menghitung gradien dari kelas target terhadap peta fitur pada lapisan konvolusi terakhir CNN, lalu menggabungkannya menjadi peta panas (*heatmap*) yang menyoroti area citra yang paling berkontribusi terhadap prediksi (Selvaraju et al., 2017; Mothkur et al., 2025). Contoh visualisasi *heatmap Grad-CAM* pada berbagai tingkat keparahan DR ditunjukkan pada Gambar 2.3.



Gambar 2.3 Visualisasi *heatmap* Grad-CAM pada berbagai kelas keparahan DR: (a) Normal, (b) *Mild*, (c) *Moderate*, (d) *Severe*, (e) *Proliferative* (Harjanto, 2025)

Dalam DR, *Grad-CAM* memungkinkan dokter untuk memverifikasi bahwa model memfokuskan perhatian pada area yang secara klinis relevan. Pada penelitian ini, selain *Grad-CAM* yang diterapkan pada lapisan konvolusi terakhir VGG19, peta atensi yang dihasilkan oleh modul *Multi-Scale Cross-Lesion Attention* turut divisualisasikan untuk memperlihatkan bagaimana model membobotkan kontribusi tiap skala fitur terhadap prediksi akhir, sehingga interpretabilitas model tidak hanya terbatas pada lapisan akhir CNN, tetapi juga pada mekanisme *cross-scale attention* itu sendiri.

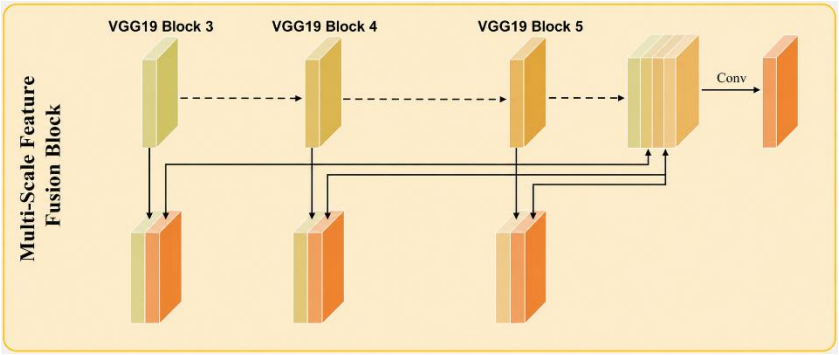
2.2.8 Graph Neural Network (GNN) dan Graph Convolutional Network (GCN)

Graph Neural Network (GNN) adalah model *deep learning* yang dirancang untuk memproses data berbentuk graf, yaitu struktur yang terdiri dari simpul (*node*) dan tepi (*edge*) yang menghubungkan simpul-simpul tersebut. Mekanisme utama GNN adalah *message passing*, di mana setiap simpul menggabungkan informasi dari tetangganya melalui tepi-tepi penghubung untuk memperbarui representasinya (Khemani et al., 2024).

Graph Convolutional Network (GCN) merupakan varian GNN yang paling mendasar dan paling banyak digunakan, yang mengagregasi fitur tetangga secara isotropik, yaitu setiap tetangga memberikan kontribusi yang relatif seragam dalam proses agregasi terlepas dari relevansi semantiknya. Dalam konteks citra *fundus* retina, keterbatasan ini berarti *patch* yang mengandung mikroaneurisma diperlakukan sama dengan *patch* latar belakang yang tidak memiliki kandungan diagnostik. Feng et al. (2023) menunjukkan bahwa integrasi CNN dan GCN mampu meningkatkan akurasi dan *F1-score* pada *grading* DR dengan membangun *node* graf dari *feature map* CNN dan *adjacency matrix* berbasis KNN. Harjanto (2025) memperluas pendekatan ini dengan menguji lima varian topologi graf (*Grid-4*, *Grid-8*, KNN adaptif k=6/8/12) dan menemukan bahwa efektivitas GCN meningkat signifikan ketika *backbone* CNN turut disesuaikan melalui *joint fine-tuning*, namun keterbatasan isotropik pada mekanisme agregasi tetap menjadi hambatan mendasar untuk pendeteksian mikrolesi yang bersifat lokal dan tersebar tidak merata.

2.2.9 *Cross-Lesion Attention* dan Mekanisme *Attention* Multiskala

Untuk meningkatkan kemampuan ekstraksi fitur lesi pada tingkat mikroskopis, penelitian ini mengintegrasikan mekanisme *Multi-Scale Cross-Lesion Attention* (MS-CLA). Mekanisme ini mengadaptasi prinsip *cross-scale context* yang dirancang untuk menangkap dependensi antar-lesi melalui proses agregasi fitur dalam pendekatan *coarse-to-fine* (Liu & Chi, 2023). Modul MS-CLA ini diimplementasikan sebagai unit *feature refiner* yang ditempatkan di antara *backbone* VGG19 dan GCN, sebagaimana diilustrasikan pada Gambar 2.4.



Gambar 2.4 Mekanisme *Multi-Scale Cross-Lesion Attention* (MS-CLA) yang diadaptasi dari Liu & Chi (2023) untuk ekstraksi fitur multiskala VGG19.

Secara teknis, MS-CLA bekerja dengan mengekstraksi tiga tingkatan representasi fitur dari kedalaman yang berbeda pada VGG19, yakni blok konvolusi ketiga, keempat, dan kelima. Setelah resolusi spasial disamakan melalui interpolasi, dilakukan operasi *cross-attention* antar-ketiga skala fitur tersebut. Proses ini bertujuan untuk memberikan bobot kontribusi yang adaptif pada setiap posisi spasial, sehingga fitur yang diteruskan ke tahap berikutnya lebih mencerminkan relevansi lintas-skala terhadap keberadaan lesi, baik itu lesi berskala kecil maupun lesi yang membentuk pola kontekstual luas.

Representasi fitur hasil MS-CLA kemudian dikonversi menjadi *node* graf untuk diproses oleh GCN. Dengan alur ini, GCN menerima *input* fitur yang telah melalui proses *gating* oleh informasi *attention*, sehingga bobot agregasi antar-*node* pada graf tidak lagi bersifat isotropik, melainkan memiliki prioritas semantik yang kuat terhadap area yang terindikasi sebagai lesi. Hal ini secara fungsional mentransformasi GCN standar menjadi *Attention-Gated GCN* yang lebih cerdas dalam memodelkan hubungan antar-fitur.

Pendekatan ini dipilih karena karakteristik lesi *diabetic retinopathy* sangat bervariasi dalam ukuran, mulai dari mikroaneurisma yang halus hingga eksudat yang meluas. Dengan menggabungkan tiga skala kedalaman yang berbeda melalui mekanisme *cross-attention* pada Gambar 2.4, MS-CLA mampu memadukan detail *fine-grained* dengan konteks semantik secara bersamaan. Hal ini memastikan bahwa informasi spasial yang diproses oleh GCN mencakup karakteristik patologis yang komprehensif, sehingga secara signifikan meningkatkan sensitivitas sistem dalam mendeteksi gejala awal *Mild DR*.

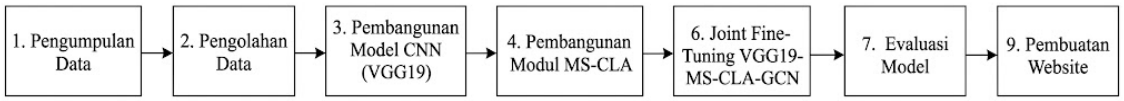
2.2.10 *Multitask Learning*

Multitask Learning (MTL) merupakan pendekatan yang melatih satu model untuk menyelesaikan beberapa tugas terkait secara simultan dengan memanfaatkan keterkaitan antartugas guna memperkaya representasi fitur (Li et al., 2025). Melalui *shared representation*, MTL dapat meningkatkan performa dan kemampuan generalisasi model pada setiap tugas. Harjanto (2025) melaporkan bahwa penambahan *auxiliary task* berupa klasifikasi biner *Mild* vs *Non-Mild* meningkatkan *recall Mild* hingga 24,7% dibandingkan CNN *baseline* tanpa penurunan akurasi global yang signifikan. Pada penelitian ini, skema MTL dua *head* yang sama dipertahankan, namun *input* GCN yang menjadi dasar kedua *head* tersebut telah diperkaya oleh modul MS-CLA, sehingga diharapkan sinyal gradien dari *auxiliary task Mild* vs *Non-Mild* dapat lebih efektif memperkuat representasi lesi yang memang sudah diboboti secara lintas-skala sejak sebelum tahap *graph encoding*.

BAB 3 METODOLOGI

3.1 Metode yang digunakan

Tahapan metodologi penelitian ini diilustrasikan pada Gambar 3.1.

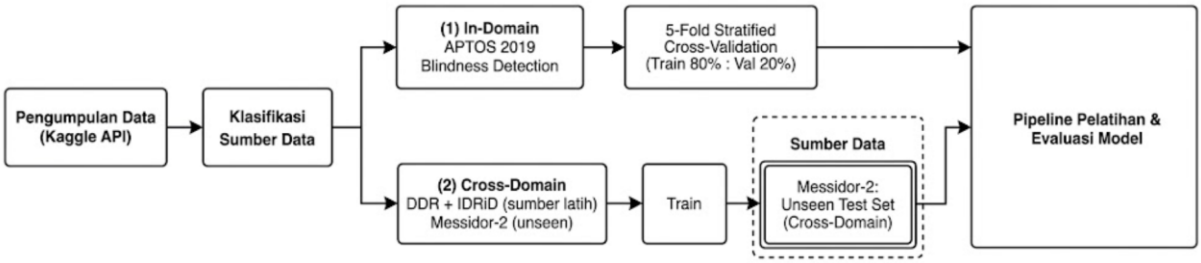


Gambar 3.1 *Flowchart* Tahapan Metodologi Penelitian

Secara garis besar, penelitian ini melibatkan sembilan tahapan utama, dimulai dari pengumpulan data, pengolahan data, hingga pengembangan sistem akhir. Alur kerja ini mencakup pembangunan model *backbone* VGG19, perancangan modul *Multi-Scale Cross-Lesion Attention* (MS-CLA) sebagai unit penyaring fitur, serta pembangunan graf dan pelatihan *Graph Convolutional Network* (GCN). Tahapan selanjutnya meliputi *joint fine-tuning* pada arsitektur VGG19-MS-CLA-GCN, implementasi *Multitask Learning* untuk dua tugas klasifikasi, evaluasi kinerja model, hingga pembuatan aplikasi web sebagai sarana inferensi. Pembaruan pada *pipeline* ini mencakup optimalisasi ekstraksi fitur melalui VGG19, integrasi modul MS-CLA untuk meningkatkan sensitivitas terhadap lesi spesifik, serta penggunaan normalisasi *LAB Color Space* untuk memastikan konsistensi kualitas citra dari berbagai sumber dataset. Seluruh tahapan tersebut akan dijelaskan lebih lanjut pada subbab berikut.

3.1.1 Pengumpulan Data

Pengumpulan data pada penelitian ini menggunakan dua kategori dataset yang memiliki karakteristik domain berbeda, yaitu dataset *in-domain* dan *cross-domain*, sebagaimana diilustrasikan pada Gambar 3.2. Pemisahan ini bertujuan untuk memenuhi kebutuhan metodologis dalam membangun model pada lingkungan yang homogen, serta mengevaluasi kemampuan generalisasi model terhadap distribusi visual yang bervariasi pada domain yang berbeda.



Gambar 3.2 Alur Pengumpulan Data.

Dataset utama untuk skenario *in-domain* adalah *APTOS 2019 Blindness Detection* yang diperoleh dari kompetisi Kaggle (*aptos2019-blindness-detection*). Sementara untuk skenario *cross-domain*, penelitian ini menggunakan tiga dataset tambahan, yaitu *Messidor-2* sebagai domain target eksternal yang tidak terlihat selama pelatihan (*unseen domain*), serta *DDR* dan *IDRiD* sebagai domain sumber untuk pengujian lintas domain. Pemilihan sumber data ini dilakukan guna memastikan konsistensi evaluasi dalam membandingkan ketahanan arsitektur model pada berbagai variasi kamera dan kondisi klinis. Distribusi data pada setiap dataset disajikan pada Tabel 3.1 berikut.

Tabel 3.1 Distribusi Keseluruhan Dataset

Dataset	Total Citra	Kelas 0	Kelas 1	Kelas 2	Kelas 3	Kelas 4
APTOS 2019	3.662	1.805	370	999	193	295
Messidor-2	1.744	1.017	270	347	75	35
IDRiD	455	129	22	156	84	64
DDR	12.522	6.266	630	4.477	236	913

Seluruh citra dari dataset pelatihan dibagi menggunakan skema *5-Fold Stratified Cross-Validation* untuk memastikan proporsi setiap kelas tetap konsisten pada tiap *fold*. Pada setiap *fold*, 80% data digunakan untuk pelatihan dan 20% untuk validasi. Dataset *Messidor-2*

digunakan sepenuhnya sebagai domain *unseen* pada tahap pengujian *cross-domain* akhir tanpa pernah digunakan selama pelatihan.

3.1.2 Pengolahan Data

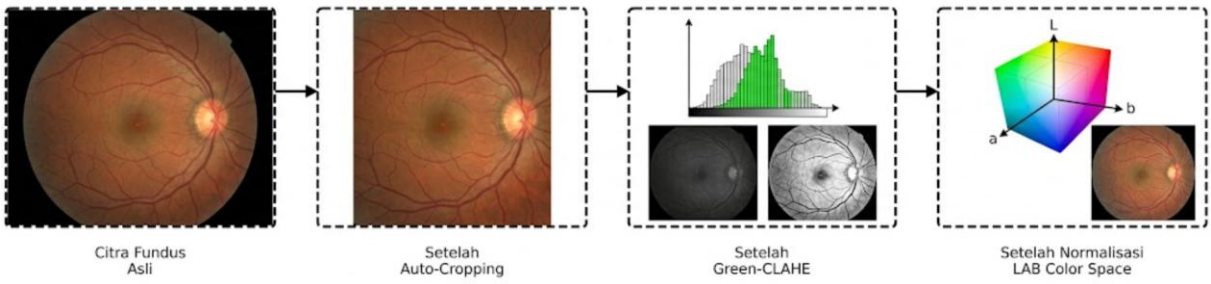
Tahap pengolahan data bertujuan meningkatkan kualitas dan konsistensi citra *fundus* sebelum digunakan sebagai input model. Metode Green-CLAHE dipilih berdasarkan hasil perbandingan lima metode praproses pada Harjanto (2025), yang menghasilkan *recall Mild* tertinggi sebesar 0,608, sebagaimana ditunjukkan pada Tabel 3.2. Selain itu, penelitian ini menerapkan normalisasi luminansi menggunakan LAB Color Space untuk mengurangi variasi pencahayaan antar-citra. Ruang warna LAB memisahkan komponen luminansi pada kanal L dari komponen warna pada kanal a* dan b*, sehingga penyesuaian kecerahan dapat dilakukan dengan tetap mempertahankan informasi warna retina.

Tabel 3.2 Perbandingan Performa CNN pada Lima Metode Praproses (Harjanto, 2025)

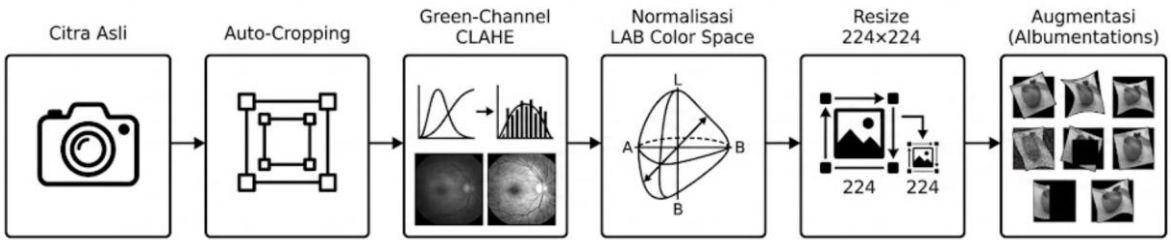
No	Metode Praproses	Accuracy	Recall Mild
1	Green-CLAHE	0,8076	**0,608**
2	Ben-Graham	0,8049	0,581
3	Denoise + CLAHE	0,8191	0,596
4	Green Hist-Equal	0,7767	0,432
5	LAB-CLAHE	0,8253	0,527

Pipeline pengolahan data terdiri atas lima tahap sebagaimana ditunjukkan pada Gambar 3.3 dan Gambar 3.4, yaitu: (1) *auto-cropping* untuk menghilangkan area latar belakang hitam menggunakan *thresholding* pada citra *grayscale*; (2) peningkatan kontras menggunakan Green-channel CLAHE dengan *clip limit* 2,0 dan *tile grid* 8×8 piksel; (3) normalisasi LAB Color Space melalui konversi RGB ke LAB dan normalisasi *min-max* pada kanal L untuk menyeragamkan luminansi, kemudian citra dikonversi kembali ke RGB; (4) *resizing* menjadi 224×224 piksel menggunakan interpolasi *bilinear* sesuai kebutuhan *backbone* VGG19; dan (5) augmentasi menggunakan Albumentations berupa *horizontal flip* (0,5), rotasi acak ±15°, *random brightness-contrast* (0,2), serta *shift-scale-rotate* dengan pergeseran 2% dan skala 8%.

Penempatan normalisasi LAB setelah Green-CLAHE dilakukan karena keduanya memiliki fungsi yang saling melengkapi. Green-CLAHE berfokus pada penguatan kontras lokal untuk memperjelas struktur dan lesi retina, sedangkan normalisasi kanal L digunakan untuk menstabilkan luminansi citra hasil peningkatan kontras. Pendekatan berbasis LAB juga telah digunakan dalam pengolahan citra *fundus* untuk meningkatkan kualitas dan konsistensi pencahayaan citra (Priyadharsini & Kannan, 2023).



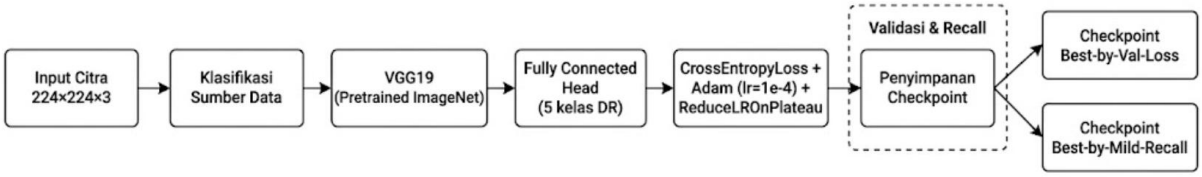
Gambar 3.3 Visualisasi Hasil Praproses Citra



Gambar 3.4 Alur Pemrosesan Data

3.1.3 Pembangunan Model CNN

Pada tahap ini dibangun model baseline berbasis CNN menggunakan VGG19 dengan *pretrained weights* ImageNet melalui pustaka *torchvision*. Model ini digunakan sebagai ekstraktor fitur sekaligus landasan sebelum integrasi modul MS-CLA dan GCN. Alur pembangunan model CNN ditunjukkan pada Gambar 3.5.



Gambar 3.5 Alur Pembangunan Model CNN

Pelatihan dilakukan menggunakan 5-Fold Stratified Cross-Validation dengan fungsi *loss* CrossEntropyLoss tanpa pembobotan kelas untuk menjaga evaluasi baseline tetap netral. Optimisasi menggunakan Adam dengan *learning rate* 1×10^{-4} dan *scheduler* ReduceLROnPlateau dengan faktor 0,5 serta *patience* 2 epoch. Pelatihan berlangsung maksimum 15 epoch dengan *early stopping* selama 5 epoch berdasarkan *validation loss* maupun *recall Mild*. Pada setiap *fold*, disimpan dua *checkpoint*, yaitu berdasarkan *validation loss* terendah dan *recall Mild* tertinggi.

VGG19 dipilih sebagai *backbone* karena memiliki arsitektur konvolusi bertingkat dengan filter 3×3 yang mendukung ekstraksi fitur mendalam pada citra *fundus* (Mateen et al., 2020). Pemilihan tersebut diperkuat melalui eksplorasi awal terhadap VGG19, VGG16, dan Swin-Tiny menggunakan protokol evaluasi yang sama, sebagaimana ditunjukkan pada Tabel 3.3.

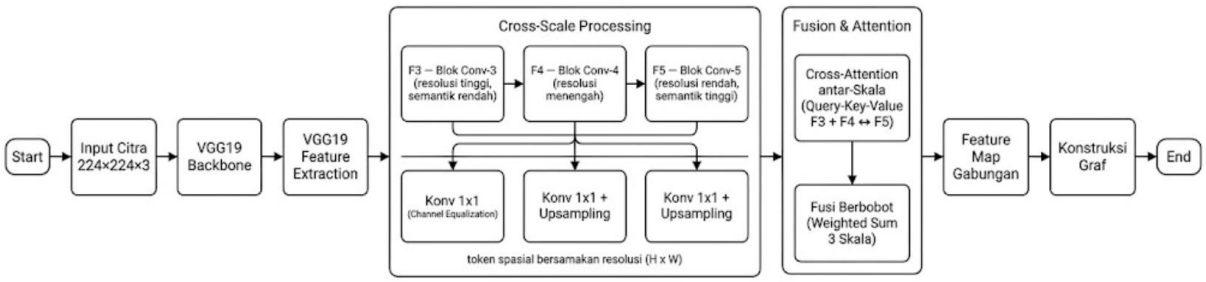
Tabel 3.3 Hasil Eksplorasi Awal Perbandingan Backbone CNN

Backbone	**Mild Recall (%)**	**Mean Accuracy (%)**	**Mean AUC**
VGG19	**90,00 ± 4,06**	**72,45**	0,9311
VGG16	88,11 ± 5,63	65,73	0,9218
Swin-Tiny	86,22 ± 6,42	71,93	**0,9367**

Hasil menunjukkan bahwa VGG19 memperoleh *recall Mild* tertinggi, yaitu 90,00 ± 4,06%, meskipun Swin-Tiny memiliki AUC sedikit lebih tinggi. Karena *recall Mild* merupakan metrik utama penelitian, VGG19 dipilih sebagai *backbone* final untuk diintegrasikan ke dalam pipeline VGG19-MS-CLA-GCN-MTL.

3.1.4 Pembangunan Modul *Multi-Scale Cross-Lesion Attention* (MS-CLA)

Modul *Multi-Scale Cross-Lesion Attention* (MS-CLA) dirancang sebagai modul penyaring fitur antara *backbone* VGG19 dan konstruksi graf, sebagaimana ditunjukkan pada Gambar 3.6. Modul ini bertujuan menggabungkan informasi fitur dari beberapa tingkat kedalaman VGG19 sehingga representasi yang digunakan pada tahap graf lebih berfokus pada lokasi yang memiliki indikasi lesi.



Gambar 3.6 Alur Pembangunan Model *Multi-Scale Cross-Lesion Attention* (MS-CLA)

MS-CLA menggunakan tiga *feature map* dari VGG19, yaitu keluaran blok konvolusi ketiga (F3), keempat (F4), dan kelima (F5) yang masing-masing merepresentasikan informasi spasial dan semantik pada tingkat berbeda. Ketiga *feature map* terlebih dahulu diproyeksikan

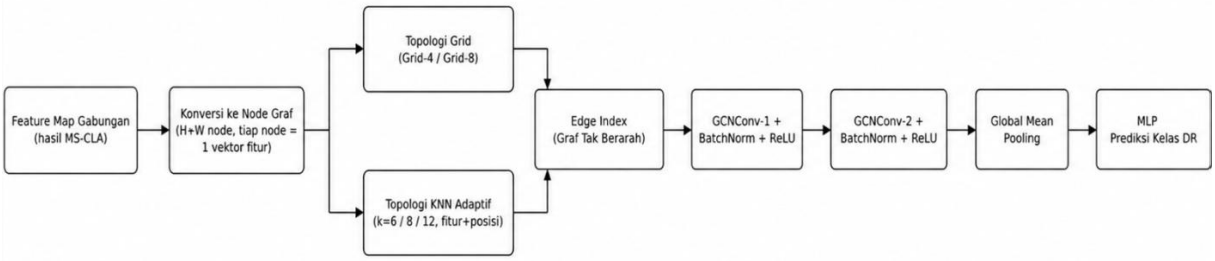
ke dimensi *channel* yang sama menggunakan konvolusi 1×1. Selanjutnya, F4 dan F5 dilakukan *upsampling* menggunakan interpolasi *bilinear* hingga memiliki resolusi spasial yang sama dengan F3.

Pada tahap *cross-attention*, setiap posisi spasial pada suatu skala menghitung kesamaan antara *query* dan *key* dari skala lainnya untuk menghasilkan bobot atensi. Bobot tersebut digunakan untuk menyeleksi dan memperkuat informasi yang relevan dari fitur *fine-grained* F3 maupun konteks semantik F4 dan F5. Ketiga fitur berbobot kemudian digabungkan melalui penjumlahan berbobot dan diproyeksikan menjadi satu *feature map* gabungan berukuran (C, H, W) sebagai masukan untuk konstruksi graf.

Dengan mekanisme tersebut, fitur yang diteruskan ke tahap graf telah mengandung informasi relevansi lintas-skala sehingga setiap node tidak hanya merepresentasikan fitur lokal, tetapi juga konteks dari tingkat fitur lainnya. Modul ini diadaptasi dari prinsip *Cross-Scale Context Attention* pada CLANet (Liu & Chi, 2023) dengan penyesuaian pada struktur dan penempatannya agar sesuai dengan arsitektur VGG19-GCN yang digunakan dalam penelitian ini. Proses *attention gating* dilakukan sebelum konstruksi graf, sedangkan operasi agregasi pada GCNConv tetap menggunakan formulasi GCN standar.

3.1.5 Pembangunan Graf dan Pelatihan GCN

Feature map hasil MS-CLA berukuran (C, H, W) dikonversi menjadi graf dengan setiap posisi spasial (h, w) direpresentasikan sebagai satu node yang memiliki vektor fitur berdimensi C. Seluruh *feature map* diekstraksi dan disimpan dalam *cache* berformat .pt untuk menghindari komputasi ulang selama pelatihan. Alur pembangunan graf dan model GCN ditunjukkan pada Gambar 3.7.



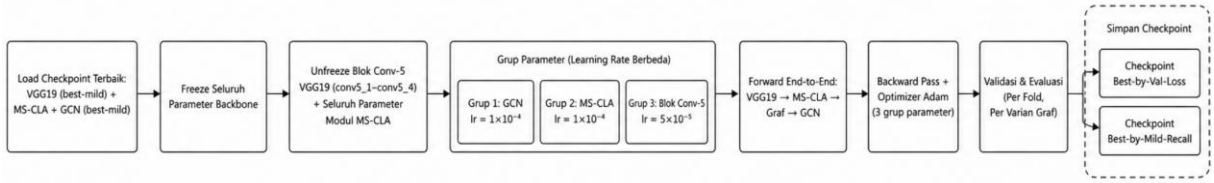
Gambar 3.7 Alur Pembangunan Graf dan Model GCN dari Node Hasil MS-CLA

Lima topologi graf yang digunakan meliputi Grid-4, Grid-8, serta KNN adaptif dengan k=6, k=8, dan k=12. Pada topologi grid, node dihubungkan berdasarkan kedekatan spasial dengan empat atau delapan tetangga, sedangkan KNN adaptif menentukan hubungan berdasarkan kombinasi *cosine similarity* fitur dan kedekatan posisi spasial. Seluruh topologi menggunakan *node feature* yang berasal dari *feature map* gabungan MS-CLA.

Model GCN terdiri atas dua lapisan GCNConv yang masing-masing diikuti *Batch Normalization* dan aktivasi ReLU. *Node embedding* kemudian diringkas menggunakan *Global Mean Pooling* dan diteruskan ke *Multilayer Perceptron* (MLP) untuk menghasilkan prediksi kelas DR. Pada tahap ini, *backbone* VGG19 dan MS-CLA dibekukan (*frozen*) sehingga hanya parameter GCN yang diperbarui. Pelatihan menggunakan CrossEntropyLoss, optimizer Adam dengan *learning rate* 1×10^{-4}, dan *scheduler* ReduceLROnPlateau dalam skema 5-Fold Cross-Validation. Setiap *fold* menyimpan dua *checkpoint*, yaitu berdasarkan *validation loss* terendah dan *recall Mild* tertinggi.

3.1.6 *Joint Fine-Tuning* VGG19-MS-CLA-GCN

Tahap *joint fine-tuning* dilakukan setelah pelatihan GCN dengan *backbone* VGG19 dan modul MS-CLA yang dibekukan. Pada tahap ini, ketiga komponen dilatih secara bersamaan dalam satu alur pembaruan gradien agar fitur VGG19, bobot *cross-attention* MS-CLA, dan representasi graf dapat saling menyesuaikan. Alur *joint fine-tuning* ditunjukkan pada Gambar 3.8.



Gambar 3.8 Alur Joint Fine-Tuning VGG19-MS-CLA-GCN

Proses dimulai dengan memuat *checkpoint* VGG19 dan GCN terbaik berdasarkan *recall Mild* dari tahap sebelumnya. Seluruh lapisan VGG19 awalnya dibekukan, kemudian blok konvolusi kelima (conv5_1 hingga conv5_4) dibuka untuk diperbarui bersama seluruh parameter MS-CLA dan GCN. Pembukaan blok terakhir VGG19 difokuskan pada adaptasi fitur tingkat tinggi terhadap pola patologis retina, sementara lapisan awal tetap dipertahankan untuk menjaga fitur dasar yang telah dipelajari.

Optimisasi menggunakan Adam dengan tiga kelompok *learning rate*, yaitu GCN sebesar 1×10^{-4}, MS-CLA sebesar 1×10^{-4}, dan blok konvolusi kelima VGG19 sebesar 5×10^{-5}. *Learning rate* yang lebih kecil pada VGG19 digunakan untuk menjaga stabilitas fitur *pretrained*, sedangkan MS-CLA dan GCN diberikan pembaruan lebih besar karena merupakan komponen yang dilatih pada arsitektur penelitian ini. *Joint fine-tuning* dilakukan selama 5 epoch per *fold* dengan *validation loss* dan *recall Mild* sebagai indikator pemilihan *checkpoint*.

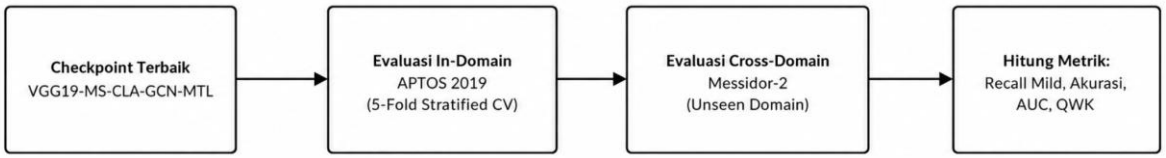
3.1.7 Pembangunan *Multitask Learning* (MTL)

Tahap *Multitask Learning* (MTL) merupakan pengembangan akhir arsitektur VGG19-MS-CLA-GCN menjadi sistem dengan dua tugas yang dilatih secara simultan. Modul MTL_GCNClassifier terdiri atas dua lapisan GCNConv sebagai *graph encoder*, dilanjutkan *Global Mean Pooling* dan *shared MLP* yang kemudian bercabang menjadi dua *output head*. *Head* multikelas menghasilkan *logits* untuk lima kelas DR, sedangkan *head* biner menghasilkan satu *logit* untuk klasifikasi Mild dan Non-Mild.

Pelatihan menggunakan kombinasi CrossEntropyLoss dengan bobot (W_{CE}=1,0) untuk tugas multikelas dan BCEWithLogitsLoss berbobot dengan (W_{BCE}=2,5) untuk tugas biner. *Learning rate* mengikuti skema *joint fine-tuning* dengan tiga kelompok parameter, yaitu GCN, MS-CLA, dan blok konvolusi kelima VGG19. Pelatihan dilakukan selama 10 epoch per *fold* dengan *early stopping* berdasarkan *validation loss* dan *recall Mild*. Label biner diperoleh langsung dari label multikelas, dengan kelas 1 ditetapkan sebagai Mild dan seluruh kelas lainnya sebagai Non-Mild, sehingga tidak diperlukan anotasi tambahan.

3.1.8 Evaluasi Model

Evaluasi model dilakukan untuk menilai performa klasifikasi secara keseluruhan serta kemampuan model dalam mendeteksi kelas Mild DR. Alur evaluasi akhir ditunjukkan pada Gambar 3.9.



Gambar 3.9 Alur Evaluasi Akhir

Metrik utama yang digunakan adalah *recall* kelas Mild DR karena penelitian berfokus pada peningkatan sensitivitas terhadap tahap awal retinopati diabetik. *Accuracy* multikelas digunakan sebagai metrik sekunder, sedangkan pada pengujian *cross-domain* menggunakan Messidor-2 ditambahkan AUC dan QWK untuk mengevaluasi kemampuan diskriminasi dan kesesuaian prediksi pada data eksternal. Evaluasi *in-domain* dilakukan menggunakan 5-Fold Stratified Cross-Validation, sehingga hasil dilaporkan dalam bentuk rata-rata dan standar deviasi dari lima *fold*.

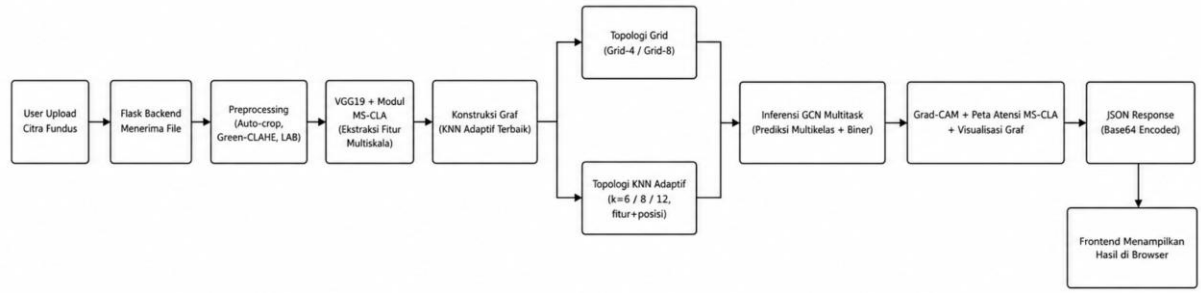
Perbandingan dilakukan pada beberapa konfigurasi model, yaitu:

1. VGG19 baseline tanpa MS-CLA dan GCN;
2. VGG19-GCN tanpa MS-CLA sebagai skenario ablasi;
3. VGG19-MS-CLA-GCN dengan *frozen backbone* pada lima varian topologi graf;
4. VGG19-MS-CLA-GCN dengan *joint fine-tuning* pada lima varian topologi graf; dan
5. VGG19-MS-CLA-GCN-MTL pada lima varian topologi graf.

Skenario ablasi VGG19-GCN digunakan untuk memisahkan kontribusi penggunaan VGG19 dari kontribusi modul MS-CLA. Dengan demikian, perubahan performa dapat dianalisis berdasarkan kontribusi masing-masing komponen arsitektur sebelum model akhir diterapkan pada pengujian *cross-domain*.

3.1.9 Pembuatan *Website*

Tahap terakhir adalah pengembangan aplikasi web interaktif menggunakan arsitektur client-server berbasis Flask sebagai backend dan HTML-CSS-JavaScript sebagai frontend. Aplikasi ini memungkinkan pengguna mengunggah citra fundus dan memperoleh hasil analisis model VGG19-MS-CLA-GCN-MTL secara real-time. Alur pembuatan website ditunjukkan pada Gambar 3.10.



Gambar 3.10 Pembuatan Website

Backend menjalankan pipeline inferensi yang identik dengan pipeline pelatihan, yaitu auto-cropping, Green-CLAHE, normalisasi LAB Color Space, ekstraksi fitur VGG19, agregasi multiskala oleh modul MS-CLA, konstruksi graf KNN adaptif (konfigurasi terbaik hasil eksperimen), inferensi multitask GCN, serta pembuatan visualisasi Grad-CAM dan peta atensi MS-CLA. Keluaran dikembalikan dalam format Base64 sehingga dapat ditampilkan langsung di browser tanpa penyimpanan file. Antarmuka pengguna menampilkan prediksi multikelas dan biner, confidence bar, visualisasi citra praproses, heatmap Grad-CAM, peta atensi lintas-skala dari MS-CLA, dan visualisasi struktur graf.

3.2 Bahan dan peralatan yang digunakan

A. Dataset

Dataset yang digunakan dalam penelitian ini terdiri atas:

- APTOS 2019 Blindness Detection, sebagai dataset utama untuk pelatihan dan validasi *in-domain*.
- Messidor-2, sebagai dataset uji eksternal untuk evaluasi *cross-domain*.
- DDR dan IDRiD, sebagai dataset tambahan untuk skenario pelatihan *cross-domain*.

B. Perangkat Lunak

Penelitian menggunakan Google Colab Pro sebagai lingkungan utama pelatihan model dengan dukungan GPU NVIDIA A100. Implementasi dilakukan menggunakan Python dengan beberapa pustaka pendukung, yaitu PyTorch dan *torchvision* untuk VGG19, PyTorch Geometric untuk GCN, Albumentations untuk augmentasi citra, scikit-learn untuk *cross-validation* dan evaluasi, serta OpenCV, NumPy, dan Pandas untuk pengolahan data. Flask digunakan untuk pengembangan *backend* aplikasi web.

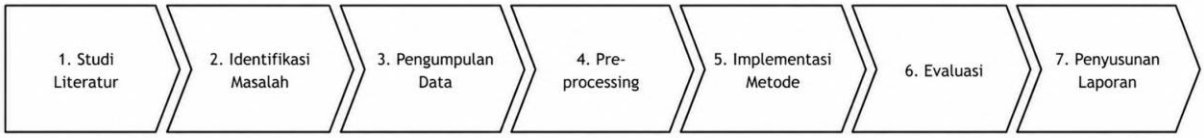
C. Perangkat Keras

Pelatihan model dilakukan menggunakan GPU NVIDIA A100 dengan VRAM 40 GB melalui Google Colab Pro. Pengembangan lokal dan pengujian aplikasi web menggunakan

perangkat dengan prosesor Intel Core i-series, RAM minimal 16 GB, serta sistem operasi Windows atau Linux.

3.3 Urutan pelaksanaan penelitian

Penelitian ini dilaksanakan melalui tujuh tahap utama sebagaimana ditunjukkan pada Gambar 3.11.



Gambar 3.11 Urutan Pelaksanaan Penelitiaan

Tahap pertama adalah studi literatur, yang mencakup kajian mengenai *Diabetic Retinopathy*, CNN dan VGG19, *cross-scale attention*, Graph Convolutional Network (GCN), dan *Multitask Learning* (MTL). Tahap kedua adalah identifikasi permasalahan, yaitu menganalisis keterbatasan arsitektur yang digunakan sebagai acuan serta merumuskan pendekatan VGG19 dengan MS-CLA dan GCN untuk meningkatkan sensitivitas deteksi Mild DR.

Tahap ketiga adalah pengumpulan data, meliputi APTOS 2019 sebagai dataset *in-domain*, DDR dan IDRiD sebagai dataset pelatihan *cross-domain*, serta Messidor-2 sebagai *unseen domain*. Tahap keempat adalah pengolahan data, yang meliputi *auto-cropping*, Green-channel CLAHE, normalisasi LAB Color Space, *resizing*, dan augmentasi menggunakan Albumentations.

Tahap kelima adalah implementasi metode, yang dilakukan secara bertahap melalui pembangunan VGG19 baseline, MS-CLA, konstruksi graf dengan lima varian topologi, pelatihan GCN, *joint fine-tuning*, MTL dengan dua *output head*, hingga pengembangan aplikasi inferensi berbasis Flask. Tahap keenam adalah evaluasi, yang dilakukan secara *in-domain* pada APTOS 2019 menggunakan 5-Fold Stratified Cross-Validation dan secara *cross-domain* pada Messidor-2. Evaluasi menggunakan *recall Mild*, *accuracy*, AUC, dan QWK serta mencakup skenario ablasi untuk menganalisis kontribusi setiap komponen model. Tahap ketujuh adalah penyusunan laporan, yaitu mendokumentasikan proses, hasil eksperimen, dan analisis penelitian dalam laporan Tugas Akhir.

3.4 Jadwal Kegiatan

Penelitian ini direncanakan berlangsung selama empat bulan. Rincian jadwal pelaksanaan setiap kegiatan disajikan pada Tabel 3.6, di mana setiap bulan dibagi menjadi dua periode yaitu minggu pertama hingga kedua (I) dan minggu ketiga hingga keempat (II).

Tabel 3.6 Jadwal Kegiatan

No	Jenis Kegiatan	Bulan															
		Bulan 1				Bulan 2				Bulan 3				Bulan 4			
1	Perumusan Masalah																
2	Studi Literatur																
3	Penyusunan Proposal																
4	Pengumpulan Data																
5	Pembuatan Model																
6	Deployment																
7	Evaluasi Model																
8	Penyusunan Laporan																

DAFTAR PUSTAKA

Aftab, S., & Akhtar, S. (2025). Diabetic retinopathy severity classification using data fusion and ensemble transfer learning. Journal of Software Engineering and Applications, 18, 1–23. https://doi.org/10.4236/jsea.2025.181001

Ahmed, N., Rahman, M. M., Ishrak, M. F., Joy, M. I. K., Sabuj, M. S. H., & Rahman, M. S. (2024). Comparative performance analysis of transformer-based pre-trained models for detecting keratoconus disease. arXiv preprint arXiv:2408.09005.

Alyoubi, W. L., Abulkhair, M. F., & Shalash, W. M. (2021). Diabetic retinopathy fundus image classification and lesions localization system using deep learning. Sensors, 21(11), 3704. https://doi.org/10.3390/s21113704

Buslaev, A., Iglovikov, V. I., Khvedchenya, E., Parinov, A., Druzhinin, M., & Kalinin, A. A. (2020). Albumentations: Fast and flexible image augmentations. Information, 11(2), 125. https://doi.org/10.3390/info11020125

Chen, H., Gomez, C., Huang, C.-M., & Unberath, M. (2022). Explainable medical imaging AI needs human-centered design: Guidelines and evidence from a systematic review. NPJ Digital Medicine, 5(156). https://doi.org/10.1038/s41746-022-00699-2

Dai, L. et al. (2021). A deep learning system for detecting diabetic retinopathy across the disease spectrum. Nature Communications, 12, 3242.

Dubey, S., & Dixit, M. (2023). Recent developments on computer aided systems for diagnosis of diabetic retinopathy: A review. Multimedia Tools and Applications, 82, 14471–14525. https://doi.org/10.1007/s11042-022-13841-9

Feng, M., Wang, J., Wen, K., & Sun, J. (2023). Grading of diabetic retinopathy images based on graph neural network. IEEE Access, 11, 98391–98401. https://doi.org/10.1109/ACCESS.2023.3312709

Harjanto, S. A. (2025). Peningkatan sensitivitas deteksi Mild Diabetic Retinopathy menggunakan arsitektur hybrid CNN-GNN dengan multitask learning [Tugas Akhir]. Institut Teknologi Sepuluh Nopember.

Hicks, S. A., Strümke, I., Thambawita, V., Hammou, M., Riegler, M. A., Halvorsen, P., & Parasa, S. (2022). On evaluation metrics for medical applications of artificial intelligence. Scientific Reports, 12(1), 5979. https://doi.org/10.1038/s41598-022-09954-8

IDF (2021). IDF Diabetes Atlas (10th ed.). International Diabetes Federation.

Khemani, B., Patil, S., Kotecha, K., & Tanwar, S. (2024). A review of graph neural networks: Concepts, architectures, techniques, challenges, datasets, applications, and future directions. Journal of Big Data, 11(18). https://doi.org/10.1186/s40537-023-00876-4

Kim, H. E., Cosa-Linan, A., Santhanam, N., Jannesari, M., Maros, M. E., & Ganslandt, T. (2022). Transfer learning for medical image classification: A literature review. BMC Medical Imaging, 22(1), 69.

Kropp, M. et al. (2023). Diabetic retinopathy as the leading cause of blindness and early predictor of cascading complications. The EPMA Journal, 14(1), 21–42.

Li, Q. et al. (2025). Multitask learning approaches in medical image analysis: A review. (dikutip dari Harjanto, 2025, sebagai rujukan sekunder untuk konsep multitask learning).

Liu, X., & Chi, W. (2023). A cross-lesion attention network for accurate diabetic retinopathy grading with fundus images. IEEE Transactions on Instrumentation and Measurement, 72, Art. no. 5029312.

Madhavi, M. V. P. L. S. K., & Kumari, M. (2024). Enrichment of retinal fundus images using EN-CLAHE and Auto-CLAHE methods. International Journal of Intelligent Systems and Applications in Engineering, 12(3), 1213–1221.

Mateen, M., Wen, J., Nasrullah, N., Sun, S., & Hayat, S. (2020). Exudate detection for diabetic retinopathy using pretrained convolutional neural networks. Complexity, 2020(1), 5801870.

Mohsen, A. et al. (2023). Retinal fundus image classification for diabetic retinopathy using transfer learning technique.

Mothkur, R., Soubhagyalakshmi, P., & Swetha, C. B. (2025). Grad-CAM based visualization for interpretable lung cancer categorization using deep CNN models. Journal of Electronics, Electromedical Engineering, and Medical Informatics, 7(3), 567–580. https://doi.org/10.35882/jeeemi.v7i3.690

Mungloo-Dilmohamud, Z. et al. (2022). Balancing data through data augmentation improves the generality of transfer learning for diabetic retinopathy classification. Applied Sciences, 12(11), 5363.

Najjar, F. H., Khudhair, Z. N., Mohamed, F., Rahim, M. S. M., Chan, V. S., & Ali, A. H. (2025). Transformer-aided skin cancer classification using VGG19-based feature encoding. Scientific Reports, 15(1), 40204.

Pavithra, S., Jaladi, D., & Tamilarasi, K. (2024). Optical imaging for diabetic retinopathy diagnosis and detection using ensemble models. Photodiagnosis and Photodynamic Therapy, 48, 104259.

Priyadharsini, C., & Kannan, R. J. (2023). Retinal image enhancement based on color dominance of image. Scientific Reports, 13, 7172. https://doi.org/10.1038/s41598-023-34212-w

Refat, S. R., Raha, Z. S., Sarker, S., Preotee, F. F., Rahman, M. M., Muhammad, T., & Alam, M. S. (2026). VR-FuseNet: A fusion of heterogeneous fundus data and explainable deep network for diabetic retinopathy classification. Biomedical Materials & Devices, 1–28.

Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. In Proc. IEEE Int. Conf. Computer Vision (ICCV) (pp. 618–626).

Simonyan, K., & Zisserman, A. (2015). Very deep convolutional networks for large-scale image recognition. In Proc. 3rd Int. Conf. Learning Representations (ICLR).

Song, Z., Shi, Z., Yan, X., Zhang, B., Song, S., & Tang, C. (2024). An improved weighted cross-entropy-based convolutional neural network for auxiliary diagnosis of pneumonia. Electronics, 13(15), 2929. https://doi.org/10.3390/electronics13152929

Sule, O., & Viriri, S. (2022). Contrast enhancement of RGB retinal fundus images for improved segmentation of blood vessels using convolutional neural networks. Journal of Digital Imaging, 36(2), 414–432. https://doi.org/10.1007/s10278-022-00738-0

Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. In Proc. 36th Int. Conf. Machine Learning (ICML 2019), PMLR 97, 6105–6114.

Teo, Z. L. et al. (2021). Global prevalence of diabetic retinopathy and projection of burden through 2045. Ophthalmology, 128(11), 1580–1591.

Terven, J., Córdova-Esparza, D.-M., Ramirez-Pedraza, A., & Chávez-Urbiola, E. A. (2025). Loss functions and metrics in deep learning. Journal of Imaging, 11(2), 33. https://doi.org/10.3390/jimaging11020033

Tsiknakis, N. et al. (2021). Deep learning for diabetic retinopathy detection and classification based on fundus images: A review. Computers in Biology and Medicine, 135, 104599.

Vanaja, C. B., & Prakasam, P. (2025). Convolutional block attention gate-based Unet framework for microaneurysm segmentation using retinal fundus images. BMC Medical Imaging, 25(83). https://doi.org/10.1186/s12880-025-01625-0

Veličković, P., Cucurull, G., Casanova, A., Romero, A., Liò, P., & Bengio, Y. (2018). Graph attention networks. In Proceedings of the 6th International Conference on Learning Representations (ICLR).

Wang, Y., Wang, L., Guo, Z., Song, S., & Li, Y. (2024). A graph convolutional network with dynamic weight fusion of multi-scale local features for diabetic retinopathy grading. Scientific Reports, 14, 5791. https://doi.org/10.1038/s41598-024-56389-4

Wang, Z., Wang, P., Liu, K., Wang, P., Fu, Y., Lu, C.-T., Aggarwal, C. C., Pei, J., & Zhou, Y. (2025). A comprehensive survey on data augmentation. arXiv preprint arXiv:2405.09591.

Xia, Z., Hu, H., Li, W., Jiang, Q., Pu, L., Shu, Y., & Sangaiah, A. K. (2024). Scheme based on multi-level patch attention and lesion localization for diabetic retinopathy grading. Computer Modeling in Engineering & Sciences. https://doi.org/10.32604/cmes.2024.030052